

Gemma vs ARC-AGI

Análise de Desempenho sob Transformações Espaciais



Metodologia de Teste

Avaliando a robustez do modelo frente a alterações na geometria e cor dos grids.

Arquitetura de Execução & Coleta de Tempo

Etapa 1: High Thinking

Implementação de **2-Step Prompting**. Esta etapa isola o raciocínio, medindo o processamento puro do grid e a geração de tokens de pensamento (ex: 456.20s). Representa **>99%** do tempo real nos chips. O overhead de rede é negligenciável (~0.1s a 0.2s).


Etapa 2: Formatação (Minimal)

Mede estritamente o tempo que o modelo levou para estruturar e extrair a tag final baseada no pensamento anterior. Extremamente rápida, durando em média apenas **~5 segundos**.

Degradação da Acurácia

A acurácia do Gemma sofre impactos severos com o aumento da complexidade espacial:

- **Original:** 76.0% (Média base)
- **Reflected:** 70.4% - Menor impacto, pois preserva a adjacência linear.
- **Rotated:** 61.2% - Queda severa. Destrói a heurística de leitura da esquerda para a direita.
- **Merged:** 44.5% - Colapso quase total devido à sobreposição de transformações e permutações de cor.



O Custo Cognitivo e Temporal

Dataset	Tempo Médio / Task	Média de Tokens / Task
Original	262.56s	12.811
Reflected (Espelhado)	304.00s	13.645
Rotated (Rotacionado)	320.92s	15.420
Merged (Misto)	369.76s	16.222

O esforço computacional aumenta inversamente à acurácia. O modelo gasta significativamente mais tempo tentando reconciliar lógicas espaciais falhas em formato de texto.



Estudos de Caso

Análise de falhas específicas e alucinações matemáticas.

Estudo 1: Rotação & Alucinação (6e26b33e)

31k+

TOKENS CONSUMIDOS

Overfitting Geométrico

A regra exigia conectar células da mesma cor formando um 'L' apenas se compartilhassem eixos. O modelo ignorou as coordenadas e alucinou conexões para formar um **retângulo fechado**.

O esforço cognitivo para justificar o erro foi massivo, resultando em mais de 500s de execução e **falha por limite de cota (HTTP 429)**.

Estudo 2: A Pegadinha da Memorização (Merged)

O Acerto Espacial

Na Task d965528e (Merged), o modelo compreendeu a transposição corretamente. O input de teste era 18x19, e o Gemma gerou perfeitamente um output de 19x18.

O Erro de Viés

Ele falhou nas cores. Em vez de deduzir a regra pelo JSON, o modelo acessou sua memória de treinamento da task original, forçando a permutação clássica (2 -> 3 -> 8 -> 2), ignorando as evidências.

Conclusões: Por que Modelos de Texto Falham?



Cegueira 2D Nativa: LLMs operam em sequências 1D (texto). Rotacionar um grid destrói a adjacência linear, forçando o modelo a calcular distâncias complexas baseadas na largura da matriz.



Sobrecarga de Memória de Trabalho: Para resolver a rotação, o modelo precisa segurar a matriz mentalmente girada no contexto textual enquanto tenta aplicar as regras lógicas, resultando em erros tipográficos.



Vulnerabilidade de Treinamento: Quando as regras naturais mudam (cores, gravidade implícita), o LLM frequentemente descarta a dedução local em favor de heurísticas previamente decoradas durante seu treinamento.

Visão Geral do Dashboard

ARC-AGI Benchmark Comparativo de Transformações - Modelo: Gemma



Dataset	Máx Tokens [CORRECT] (Task → Orig)	Mín Tokens [CORRECT] (Task → Orig)	Máx Tokens [INCORRECT] (Task → Orig)	Máx Tempo [CORRECT] (Task → Orig)	Mín Tempo [CORRECT] (Task → Orig)	Máx Tempo [INCORRECT] (Task → Orig)
Original (Treino)	36,073 (a2b02240 → b2b02240)	2,510 (a410a000 → a410a000)	38,288 (a0d75000 → a0d75000)	400.19s (400400ad → 400400ad)	17.55s (a410a000 → a410a000)	520.19s (01430200 → 01430200)
Rotated	39,629 (777ed153 → 20ac709e)	2,828 (20ac7152 → a031009e)	38,543 (44711707 → 802de09e)	731.86s (802de09e → 543a7e05)	50.45s (20ac7152 → a031009e)	881.80s (258000f1 → 6ac0119e)
Reflected	40,174 (db4000ee → 08000002)	1,528 (0ac79500 → 2e300400)	40,279 (0a542007 → 3e320000)	815.06s (70071700 → 0ac00000)	20.94s (bedf5000 → 305b0400)	875.80s (bedf5000 → 305b0400)
Merged	22,719 (1b000000 → 7037ed04)	2,310 (a0217007 → a0217007)	37,187 (4b420000 → 40000000)	808.28s (40000000 → 0e20070e)	87.70s (02130000 → 010d070e)	911.08s (08001000 → a0701000)