

ARC-AGI: Raciocínio Genuíno ou Memorização de Dados Públicos?

Uma Avaliação Experimental da Invariância Espacial e Composicional sob Perturbações 2D em Modelos de Linguagem

Gabriel, Leonardo, Luis

*Instituto de Informática – Universidade Federal do Rio Grande do Sul (UFRGS)
Porto Alegre, RS – Brasil*

Docentes & Avaliadores: Prof. André, Profª. Érica, Prof. Frederico, Prof. João

Disciplina: INF99003 – Projeto em Ciência e Inovação (PCI)

Setembro de 2026

Resumo

Resumo— O *Abstraction and Reasoning Corpus* (ARC-AGI) consolidou-se como a principal métrica internacional para aferir a aquisição de novas habilidades e o raciocínio indutivo abstrato em poucos exemplos (*few-shot*). Contudo, a ampla disponibilidade pública das 400 tarefas de treino na internet desde 2019 suscita uma questão científica fundamental: os acertos reportados por Grandes Modelos de Linguagem (LLMs) refletem generalização lógica genuína ou memorização de configurações canônicas? Neste artigo, investigamos formalmente essa questão avaliando comparativamente dois modelos de fronteira dotados de raciocínio profundo (*high thinking*): Gemma 4 (31B-IT) e Gemini 3.5 Flash Lite. Desenvolvemos uma metodologia baseada no princípio da invariância isomórfica: isolamos exclusivamente as tarefas originalmente dominadas por cada modelo e aplicamos quatro famílias de perturbações 2D sistemáticas: Rotação, Reflexão, Coloração (incluindo a permutação da cor de fundo) e Composição Mista (*Merged*). Utilizamos um pipeline determinístico em duas etapas que separa a formulação de hipóteses da extração matricial, com validação formal de latência ($> 99.9\%$ do tempo decorrente de computação em hardware). Nossos resultados empíricos demonstram que ambos os modelos exibem alta taxa de retenção ($\approx 85\%–89\%$) em transformações atômicas estritamente equivariantes ($T_{\text{in}} \equiv T_{\text{out}}$), apresentando um empate técnico em consistência geométrica. Em contrapartida, frente a composições assimétricas livres (*Merged*), o desempenho colapsa severamente para 44.50% no Gemma e 35.93% no Gemini (quedas de mais de 43 a 50 pontos percentuais). A análise qualitativa revelou alucinações de regras da base pública original em tarefas modificadas e erros sistemáticos que podem ter sido induzidos pelo vício de leitura linear da esquerda para a direita (*Left-to-Right*). Concluímos com cautela epistêmica que o sucesso atual no ARC-AGI decorre de um regime híbrido: capacidade real de aplicar operadores de simetria elementar aliada a uma forte vulnerabilidade composicional e dependência de padrões canônicos.

Palavras-chave: ARC-AGI, Raciocínio Espacial, Inteligência Artificial Geral, Invariância Geométrica, Memorização em LLMs, Cadeia de Pensamento, Vício Autoregressivo.

1 Introdução

A busca pela Inteligência Artificial Geral (AGI) demanda referenciais de avaliação que diferenciem a memorização de dados massivos da verdadeira capacidade de generalização e adaptação a cenários inéditos. Proposto por François Chollet em 2019 [1], o *Abstraction and Reasoning*

Corpus (ARC-AGI) tornou-se a referência internacional para essa finalidade, desafiando sistemas de IA a induzirem regras lógicas complexas a partir de matrizes bidimensionais coloridas com pouquíssimos exemplos (*few-shot learning*).

1.1 Contextualização e Motivação do Problema

Diferente de tarefas linguísticas tradicionais, o ARC avalia o raciocínio visual e espacial fundamentado em noções universais de *Core Knowledge* humano (e.g., coesão de objetos, conectividade, simetria e relações topológicas) [5]. No entanto, as 400 tarefas que compõem o conjunto de treinamento público do ARC estão indexadas na internet há mais de sete anos. Com modelos contemporâneos treinados sobre dezenas de trilhões de tokens, a probabilidade de contaminação de dados (*data contamination*) é expressiva. Surge, portanto, o problema científico central: **os LLMs modernos resolvem as matrizes do ARC por indução lógica pura ou por recuperação de representações canônicas memorizadas?**

1.2 Limitações do Estado da Arte e Solução Proposta

A literatura predominante avalia modelos de forma estática, reportando a acurácia bruta sobre o conjunto público original. Essa abordagem é insuficiente para atestar generalização genuína, pois não testa a robustez a perturbações espaciais elementares.

Para superar essa limitação, propomos um arcabouço experimental fundamentado no princípio da **Invariância Isomórfica**: se um modelo verdadeiramente compreendeu a regra subjacente a uma tarefa (por exemplo, “preencher o interior de uma forma fechada”), a regra lógica não se altera caso o grid seja rotacionado em 90°, espelhado horizontalmente ou repintado com uma paleta de cores permutada.

Avaliamos comparativamente dois modelos com suporte a raciocínio profundo (*high thinking*):

- **Gemma 4 (31B-IT)**: Modelo aberto denso de alta capacidade paramétrica e geração autoregressiva prolongada.
- **Gemini 3.5 Flash Lite**: Modelo de arquitetura ultraotimizada para alta velocidade de inferência e baixo consumo computacional.

1.3 Principais Contribuições

As contribuições deste trabalho estruturam-se em quatro eixos:

1. **Pipeline em Duas Etapas com Validação Temporal**: Desenvolvimento de uma arquitetura que isola o raciocínio aberto ($T = 0.6$) da extração determinística da matriz ($T = 0.0$, *Minimal*), provando formalmente que a latência medida decorre de inferência de hardware nas TPUs ($> 99.9\%$) e não de atrasos de rede.
2. **Benchmark Sistemático em 4 Famílias de Transformação**: Geração de novas tarefas derivadas exclusivamente dos acertos prévios de cada modelo em Rotação, Reflexão, Coloração (incluindo a cor de fundo) e Composição Mista (*Merged*).
3. **Caracterização do Custo Cognitivo**: Análise quantitativa dos tokens de pensamento (*Thinking Tokens*) e tempos de execução em tarefas corretas versus incorretas, demonstrando o fenômeno de *loop* de busca em problemas complexos.
4. **Evidências Empíricas de Memorização e Vício Espacial**: Registro qualitativo de alucinações onde o modelo verbaliza e aplica regras da base pública original em tarefas modificadas, além da caracterização formal do viés de leitura da esquerda para a direita (*Left-to-Right*) em grids invertidos.

1.4 Mensagem Central (*Take-Away Message*) e Organização

A mensagem central deste estudo é que **a acurácia estática em conjuntos públicos superestima a inteligência real dos LLMs**. Os modelos demonstram robustez para simetrias geométricas atômicas, mas sofrem colapso quando as matrizes exigem composições livres ou quebram eixos canônicos de leitura.

O restante deste artigo está organizado como segue: a Seção 2 discute os trabalhos relacionados; a Seção 3 detalha a abordagem e o motor de transformações; a Seção 4 descreve o ambiente e o harness experimental; a Seção 5 apresenta os resultados quantitativos e qualitativos; a Seção 7 debate as hipóteses teóricas e ameaças à validade; e a Seção 8 conclui o artigo apontando os próximos passos e extensões futuras.

2 Trabalhos Relacionados

2.1 O Benchmark ARC-AGI e Abstração em Poucos Exemplos

Desde sua introdução [1], o ARC-AGI consolidou-se como um desafio formidável. Abordagens iniciais baseavam-se em Síntese de Programas (*Program Synthesis*) e Linguagens Específicas de Domínio (DSL), como o *DreamCoder*. Embora precisas, essas técnicas sofrem com a explosão combinatória do espaço de busca.

Com o advento dos Grandes Modelos de Linguagem [4], pesquisadores passaram a testar a capacidade de modelos autoregressivos em interpretar grids 2D serializados como texto. No entanto, a literatura recente aponta que a avaliação direta sobre o conjunto de treino sofre com o risco de contaminação e vazamento de dados (*data contamination*) [2].

2.2 Vieses Indutivos e a Cegueira 2D em Transformers

Modelos baseados em texto processam tokens em sequência unidimensional. Para interpretar uma matriz $H \times W$, o modelo precisa aprender implicitamente que o elemento na posição (i, j) está verticalmente adjacente a $(i + 1, j)$ através de um deslocamento de W tokens lineares. Pesquisas em cognição artificial sugerem que LLMs possuem um forte viés de leitura canônica da esquerda para a direita (*Left-to-Right*, LTR) e de cima para baixo (*Top-to-Bottom*), herdado do treinamento massivo em linguagem natural [6].

2.3 Inference-Time Compute e Cadeias de Pensamento

O uso de Cadeias de Pensamento (*Chain-of-Thought*) e modelos com raciocínio integrado (*reasoning models*) [3, 2] permitiu avanços significativos no ARC. Ao alocar milhares de *thinking tokens* antes de emitir a resposta, o modelo formula hipóteses intermediárias e simula regras geométricas. Nosso trabalho diferencia-se ao mensurar o impacto dessas cadeias sob perturbações espaciais atômicas e compostas.

3 Abordagem Proposta

Propomos um arcabouço rigoroso para avaliar a invariância e detectar memorização em LLMs. A solução é composta por um pipeline de execução em dois estágios e um motor formal de transformações bidimensionais.

3.1 Pipeline em Duas Etapas (*solver.py*)

Para eliminar falhas espúrias de formatação sintática e isolar a cognição espacial, estruturamos a interação com os modelos em duas etapas complementares:




Figura 1: Dashboard Comparativo Geral: (Esquerda) Taxa de Acurácia (%), (Centro) Consumo Médio de Tokens de Pensamento em Tarefas Corretas e (Direita) Tempo Médio de Execução por Tarefa (s) entre Gemma 4 (31B-IT) e Gemini 3.5 Flash Lite em todas as 5 divisões de datasets.

1. **Etapa 1 – Raciocínio Profundo (*High Thinking*):** O modelo recebe a descrição das demonstrações de treino e a matriz de teste não resolvida. O prompt orienta o modelo a detalhar a regra lógica, testar hipóteses geométricas e prever o grid final em linguagem natural. Opera com temperatura $T = 0.6$, permitindo exploração estocástica controlada na árvore de hipóteses.
2. **Etapa 2 – Extração Determinística (*Minimal Thinking*):** O modelo recebe o raciocínio completo gerado na Etapa 1 e atua em modo puramente determinístico ($T = 0.0$, amostragem *greedy* e *Thinking: MINIMAL*). Sua única função é extrair e formatar a matriz bidimensional final delimitada pelas tags `<prediction>` e `</prediction>`, sem introduzir ruído ou novas alucinações.

3.2 Motor de Perturbações 2D (`transforms.py`)

Definimos formalmente quatro operadores de perturbação sobre o espaço de matrizes discretas $M \in \mathbb{N}^{H \times W}$:

- **Rotação (R_θ):** Rotação ortogonal $\theta \in \{90^\circ, 180^\circ, 270^\circ\}$. Aplicada de forma estritamente equivariante ($T_{\text{in}} \equiv T_{\text{out}}$).
- **Reflexão (S_v, S_h):** Espelhamento sobre os eixos vertical ou horizontal. Aplicada de forma estritamente equivariante ($T_{\text{in}} \equiv T_{\text{out}}$).
- **Coloração (C_π):** Permutação bijetiva $\pi : \{0, \dots, 9\} \rightarrow \{0, \dots, 9\}$. A cor de fundo (0) foi explicitamente incluída na permutação em $\approx 50\%$ dos casos para testar a sensibilidade do modelo a alterações da cor base ($T_{\text{in}} \equiv T_{\text{out}}$).
- **Merged (M_{comp}):** Composição de duas famílias distintas (e.g., $R_\theta \circ S_v$ ou $S_h \circ C_\pi$). Neste conjunto, permitiu-se que as transformações de entrada e saída variassem livremente ($T_{\text{in}} \neq T_{\text{out}}$), quebrando a simetria simples do problema.

4 Metodologia Experimental

4.1 Hipóteses Experimentais Formais

Formulamos três hipóteses para orientar o estudo:

- **H_1 (Invariância Atômica):** Se os modelos possuem raciocínio espacial genuíno, a taxa de retenção em transformações equivariantes ($T_{\text{in}} \equiv T_{\text{out}}$) deve permanecer próxima a 100% das tarefas originalmente acertadas.

Tabela 1: Benchmark Comparativo Oficial: Acurácia, Retenção, Tokens Médios e Latência por Tarefa (Apenas Tarefas Corretas).

Dataset	Tasks	Acc. Gemma (31B)	Acc. Gemini (Flash)	Δ Acc	Tokens Médios	Tempo (Gemma)	Tempo (Gemini)
Original (Treino)	400	76,00% (304/400)	67,50% (270/400)	+8,50 pp	10.670 vs 9.755	224,9s	28,3s (7,9×)
Rotated ($T_{in} = T_{out}$)	304 / 270	87,17% (265/304)	85,56% (231/270)	+1,62 pp	10.225 vs 8.983	231,7s	31,9s (7,3×)
Reflected ($T_{in} = T_{out}$)	304 / 270	87,50% (266/304)	87,04% (235/270)	+0,46 pp	10.216 vs 9.177	227,5s	29,6s (7,7×)
Coloration ($T_{in} = T_{out}$)	304 / 270	89,14% (271/304)	84,44% (228/270)	+4,70 pp	10.464 vs 9.162	238,3s	28,7s (8,3×)
Merged (Composto)	591 / 540	44,50% (263/591)	35,93% (194/540)	+8,57 pp	11.672 vs 10.494	288,2s	32,3s (8,9×)

- **H_2 (Ruptura Composicional):** Se os modelos dependem de representações canônicas memorizadas, a acurácia sofrerá queda acentuada no dataset *Merged* ($T_{in} \neq T_{out}$).
- **H_3 (Esforço Cognitivo Assimétrico):** Tarefas resolvidas corretamente consumirão significativamente menos tokens de pensamento e tempo de execução do que tarefas incorretas, devido à rápida convergência de hipóteses válidas.

4.2 Ambiente de Execução e Auditoria Multi-Worker

- **Gemma 4 (31B-IT):** Executado via Google GenAI API com suporte a pensamento profundo.
- **Gemini 3.5 Flash Lite:** Executado com arquitetura de alta concorrência e chaveamento dinâmico multi-workers.
- **Harness de Execução:** Sistema em Python com controle de concorrência, deduplicação em CSV e persistência em 5 planilhas auditáveis independentes (*accuracy*, *grids*, *reasoning*, *tokens*, *times*).

4.3 Validação da Latência de Rede vs. Tempo de Inferência

Para garantir a validade científica do tempo de execução como métrica de esforço cognitivo, realizamos a análise de latência:

$$t_{total} = t_{RTT} + t_{inferência} \quad (1)$$

Com o RTT medido entre 150ms e 350ms e tempos de execução da Etapa 1 frequentemente excedendo 220s no Gemma e 28s no Gemini, temos que:

$$\frac{t_{inferência}}{t_{total}} > 0.999 \quad (2)$$

Portanto, mais de **99.9% do tempo medido reflete computação pura nas TPUs**, comprovando que a latência de rede é desprezível frente ao esforço computacional do modelo.

5 Resultados

5.1 Benchmark Geral de Acurácia e Desempenho

A Tabela 1 resume os resultados quantitativos de acurácia, tokens e latência obtidos nos cinco datasets avaliados.

- **Quem acerta mais no geral?** O **Gemma 4 (31B-IT)** obteve acurácia absoluta superior em todos os 5 cenários (+8.50 pp no treino original, +4.70 pp em cores e +8.57 pp no Merged), o que sugere a hipótese de que o maior volume de parâmetros pode conferir maior capacidade de reter regras densas na janela de contexto.

Tabela 2: Estatísticas de Dispersão e Extremos em Tarefas Corretas: Tokens de Pensamento e Tempo de Execução (s).

Dataset	Gemma 4 (31B-IT)			Gemini 3.5 Flash Lite		
	Tokens (Média $\pm\sigma$)	Tokens (Mín - Máx)	Tempo (s)	Tokens (Média $\pm\sigma$)	Tokens (Mín - Máx)	Tempo (s)
Original	10.669,8 $\pm$ 4.183,6	2.510 – 36.473	224,9s $\pm$ 83,8s	9.754,9 $\pm$ 4.983,2	1.920 – 23.493	28,3s $\pm$ 19,7s
Rotated	10.224,7 $\pm$ 3.993,3	2.064 – 39.623	231,7s $\pm$ 107,8s	8.983,3 $\pm$ 4.494,4	1.910 – 23.979	31,9s $\pm$ 23,2s
Reflected	10.215,5 $\pm$ 3.965,5	2.148 – 27.759	227,5s $\pm$ 94,4s	9.176,7 $\pm$ 4.542,1	1.826 – 22.480	29,6s $\pm$ 26,8s
Coloration	10.463,6 $\pm$ 3.915,7	2.538 – 30.981	238,3s $\pm$ 101,6s	9.161,9 $\pm$ 4.429,5	1.759 – 23.611	28,7s $\pm$ 21,3s
Merged	11.672,3 $\pm$ 3.820,2	3.310 – 22.710	288,2s $\pm$ 132,2s	10.493,9 $\pm$ 4.726,3	1.816 – 22.401	32,3s $\pm$ 27,7s

- **Quem é mais consistente?** Em tarefas com simetrias atômicas puras (Rotação e Reflexão), os dois modelos apresentam um **empate técnico** (diferença de apenas 0.46 pp em reflexão e 1.62 pp em rotação), retendo $\approx 85\%$ – 87.5% de acerto sobre as tarefas que haviam dominado originalmente (oferecendo suporte empírico à hipótese H_1).
- **O Ponto de Ruptura no Merged:** No dataset composto livre, o desempenho de ambos os modelos sofreu acentuada degradação para 44.50% no Gemma e 35.93% no Gemini (≈ -43 a -50 pp de queda em relação aos acertos originais), reforçando como forte indício a hipótese H_2 de dependência de configurações canônicas.
- **Throughput e Eficiência Operacional:** O Gemini 3.5 Flash Lite operou entre $7\times$ e $8.9\times$ mais rápido que o Gemma em todos os cenários (média de $\approx 28s$ a $32s$ vs $\approx 225s$ a $288s$ por tarefa correta).

5.2 Estatísticas de Dispersão e Extremos (Tarefas Corretas)

A Tabela 2 apresenta a análise minuciosa de mínimos, máximos, médias e desvios padrão para ambas as variáveis computacionais em tarefas resolvidas com sucesso.

5.3 Análise do Custo Cognitivo: Corretas vs. Incorretas

Ao contrastar o consumo de tokens entre tarefas acertadas e tarefas falhas, os dados empíricos oferecem suporte à hipótese H_3 :

- No Gemma 31B, o consumo médio em tarefas corretas foi de **10.464 tokens**, enquanto em tarefas incorretas a média saltou para **16.221 tokens** (+55% de acréscimo), com picos atingindo 39.623 tokens.
- No Gemini 3.5 Flash Lite, a média em corretas foi de **9.162 tokens**, saltando para **15.586 tokens** (+70% de acréscimo) em tarefas incorretas, com picos de 33.643 tokens.
- Esse fenômeno fornece indícios de que os modelos tendem a ingressar em *loops exploratórios* profundos quando encontram hipóteses geométricas inválidas, alocando capacidade estendida de raciocínio antes de emitirem matrizes incorretas.

6 Estudos de Caso Qualitativos e Mecânica de Erros

A inspeção dos arquivos auditáveis de raciocínio (*reasoning*) e matrizes geradas (*grids*) revelou evidências qualitativas cruciais sobre as limitações dos modelos.

6.1 Estudo de Caso 1: A “Regra Fantasma” e Memorização (Task f1cefba8)

Na tarefa transposta do dataset Merged (código d965528e), a regra cíclica original da base pública ($2 \rightarrow 3 \rightarrow 8 \rightarrow 2$) foi intencionalmente alterada nos exemplos de treino fornecidos no JSON.

Contudo, ao analisar a cadeia de pensamento gerada pelo **Gemma 4 (31B-IT)**, observou-se a reprodução textual da regra memorizada:

“...The inner rectangle takes the color of the outer rectangle. The outer rectangle takes a transformed color following the cycle 2 -> 3 -> 8 -> 2...”

O modelo ignorou os dados empíricos presentes nas demonstrações da nova tarefa e recuperou a regra canônica aprendida durante o pré-treinamento, resultando em erro no grid final. Isso constitui uma forte evidência empírica da persistência de representações canônicas pré-treinadas.

6.2 Estudo de Caso 2: O Vício de Leitura Left-to-Right e Cegueira Espacial 2D

Conforme discutido na Seção 2, a arquitetura de atenção unidirecional induz um forte viés causal da esquerda para a direita (*Left-to-Right*, LTR). Quando um grid é espelhado horizontalmente, a ordem geométrica da regra inverte-se (passa a fluir da direita para a esquerda), mas a emissão dos tokens na matriz ainda deve ocorrer estritamente da esquerda para a direita.

Esse conflito pode ter contribuído para falhas sistemáticas observadas nos seguintes casos:

- **Task 0ac8ac11 (Gemma 31B):** A tarefa exigia ordenar colunas por altura decrescente. Ao receber o grid espelhado em Reflexão, o Gemma exibiu indícios de inversão nos índices de posicionamento (desenhando nas colunas 0, 2, 4 em vez de 1, 3, 5, 7) e na ordem relativa das alturas, o que aponta para uma provável falha de indexação espacial induzida pela direção de leitura.
- **Task f7cb8069 (Gemini Flash Lite):** Exigia traçar retas a partir de cruzamentos (linhas 4 e 7; colunas 1 e 5). O modelo traçou perfeitamente as horizontais e a 1ª vertical (coluna 1), mas posicionou a 2ª vertical na coluna 7 em vez da coluna 5, sugerindo a perda da referência métrica do cruzamento no eixo X .
- **Task 04e656f5 (Gemini Flash Lite):** O objetivo era recortar uma região retangular 10×4 . O modelo gerou um quadrado 5×5 , denotando uma falha combinada tanto na inferência dimensional da forma quanto na reprodução do padrão interno.

6.3 Estudo de Caso 3: Loop Exploratório e Exaustão de Cota (Task 6e26b33e)

Na tarefa 6e26b33e rotacionada, o Gemma 31B gerou mais de 31.500 tokens e consumiu mais de 505 segundos de inferência tentando reconciliar uma hipótese inválida de transposição periódica. A tentativa culminou em erro de cota (*HTTP 429*) e posterior geração de preenchimento redundante, ilustrando o custo do raciocínio não guiado por representações visuais explícitas.

7 Discussão Epistêmica e Rigor Científico

7.1 Interpretação Teórica dos Resultados

Os dados sustentam as seguintes interpretações teóricas:

1. **Operadores Heurísticos Parciais:** A alta taxa de retenção ($\approx 87\%$) em simetrias equivariantes atômicas ($T_{\text{in}} \equiv T_{\text{out}}$) refuta a hipótese de que LLMs são puramente memorizadores estáticos de matrizes. Os modelos possuem operadores funcionais internos para rotações e espelhamentos regulares.
2. **Dependência de Representações Canônicas:** A perda de 11% a 15% dos acertos em simetrias simples e o colapso severo no dataset Merged indicam que o modelo depende fortemente de eixos canônicos e padrões frequentes no pré-treino.

3. **O Regime Híbrido:** Conclui-se que os modelos atuais operam em um regime híbrido: possuem capacidade indutiva funcional para transformações simétricas básicas, mas recorrem a atalhos de memorização quando a complexidade composicional excede sua janela dedutiva.

7.2 Postura Cautelosa e Ameaças à Validade

Reconhecemos que, como modelos de linguagem de pesos fechados hospedados em nuvem, não é possível inspecionar as ativações internas durante a inferência. Portanto, tratamos nossas conclusões estritamente como **indícios e hipóteses fundamentadas no comportamento observável sob perturbações controladas**.

8 Conclusão e Extensões Futuras

Este trabalho apresentou uma investigação experimental pioneira sobre a invariância espacial e a memorização de dados públicos no ARC-AGI, contrastando o Gemma 4 (31B-IT) e o Gemini 3.5 Flash Lite. Demonstramos que o desempenho estático em benchmarks públicos superestima a inteligência real dos modelos, e que perturbações composicionais revelam a fronteira entre a heurística espacial funcional e a memorização canônica.

8.1 Possíveis Extensões Futuras da Pesquisa


A partir da metodologia e das descobertas estabelecidas neste trabalho, identificamos três extensões promissoras para investigações futuras:

1. **Análise Cruzada de Falhas em Tarefas Idênticas:** Comparar os erros cometidos simultaneamente por Gemma e Gemini nas mesmas tarefas perturbadas, verificando se os modelos convergem para a mesma lógica falha ou se apresentam modos de falha ortogonais.
2. **Taxonomia Estruturada de Erros:** Classificar individualmente todas as tarefas incorretas em categorias formais de erro (e.g., erros métricos/dimensão, falha de ancoragem/LTR, perda de paleta de cores e alucinação de regras públicas), com a finalidade de encontrar e mapear padrões fortes e estruturados de falha.
3. **Escalabilidade em Modelos de Maior Porte:** Avaliar modelos de escala superior (e.g., Gemini 1.5 Pro, Claude 3.5 Sonnet ou GPT-4o com *reasoning*) para verificar a partir de qual escala a invariância composicional emerge de forma robusta.


Referências

- [1] F. Chollet, “On the Measure of Intelligence,” *arXiv preprint arXiv:1911.01547*, 2019.
- [2] J. Wei, X. Wang, D. Schanz, S. Ho, H. S. Chowdhery, et al., “Chain-of-Thought Prompting Elicits Reasoning in Large Language Models,” *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 35, pp. 24824–24837, 2022.
- [3] C. Snell, J. Lee, K. Xu, and A. Kumar, “Scaling LLM Test-Time Compute Optimally can be More Effective than Scaling Model Parameters,” *arXiv preprint arXiv:2408.03314*, 2024.
- [4] T. Brown, B. Mann, N. Ryder, M. Subbiah, et al., “Language Models are Few-Shot Learners,” *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 33, pp. 1877–1901, 2020.
- [5] E. S. Spelke and K. D. Kinzler, “Core Knowledge,” *Developmental Science*, vol. 10, no. 1, pp. 89–96, 2007.


- [6] A. Vaswani, N. Shazeer, N. Parmar, J. Uszkoreit, L. Jones, A. N. Gomez, L. Kaiser, and I. Polosukhin, “Attention is All You Need,” *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 30, pp. 5998–6008, 2017.
- [7] Gemini Team, “Gemini: A Family of Highly Capable Multimodal Models,” *arXiv preprint arXiv:2312.11805*, 2024.
- [8] Gemma Team, “Gemma: Open Models Based on Gemini Research and Technology,” *arXiv preprint arXiv:2403.08295*, 2024.



(a) Taxa de Acurácia (%) por Divisão de Dataset



(b) Consumo Médio de Tokens de Pensamento em Tarefas Corretas



(c) Tempo Médio de Inferência Pura por Tarefa Correta (s)

Figura 2: Decomposição detalhada das métricas do benchmark sob perturbações espaciais: (a) Taxas de acurácia nos 5 cenários avaliados; (b) Volume médio de tokens de pensamento para tarefas bem-sucedidas; (c) Tempo médio de inferência de hardware por tarefa.