

ARC-AGI: Raciocínio ou Memorização?

Uma Avaliação Experimental da Invariância Espacial e Composicional sob Transformações em Modelos de Linguagem

Gabriel Pieruccini Knopp

Leonardo Greco Fin

Luis Henrique Caselani Macedo Junior

*Instituto de Informática – Universidade Federal do Rio Grande do Sul (UFRGS)
Porto Alegre, RS – Brasil*

Docentes & Avaliadores: Prof. André Grahl Pereira, Profa. Érika Fernandes Cota,

Prof. Frederico Messa Schwartzhaupt, Prof. João Cesar Netto

Disciplina: INF99003 – Projeto em Ciência e Inovação (PCI)

Setembro de 2026

Resumo

Resumo— O *Abstraction and Reasoning Corpus* (ARC-AGI) consolidou-se como um dos principais referenciais para avaliar a capacidade de raciocínio abstrato em inteligências artificiais com poucos exemplos (*few-shot*). No entanto, como as 400 tarefas do conjunto de treino público estão disponíveis na internet desde 2019, surge uma dúvida fundamental: os modelos de linguagem realmente aprendem a raciocinar sobre as matrizes ou apenas recuperam respostas e regras memorizadas no pré-treinamento? Neste trabalho, investigamos essa questão comparando dois modelos com suporte a pensamento profundo: o Gemma 4 (31B-IT) e o Gemini 3.5 Flash Lite. Desenvolvemos uma metodologia baseada no teste de invariância: selecionamos as tarefas que cada modelo havia acertado na base original e geramos novas matrizes aplicando transformações de Rotação, Reflexão, Coloração (incluindo a cor de fundo) e Composição Livre (*Merged*). Para evitar falhas sintáticas, utilizamos um fluxo em duas chamadas: uma de raciocínio aberto e outra de extração determinística da matriz final. Os resultados mostram que ambos os modelos mantêm alta consistência ($\approx 85\%$ a 89%) em transformações isoladas de simetria (rotação, reflexão e cores), apresentando desempenho quase equivalente. Contudo, quando múltiplas transformações são combinadas simultaneamente no conjunto Merged, a acurácia despenca para 44, 50% no Gemma e 35, 93% no Gemini (quedas de mais de 40 a 50 pontos percentuais). A análise qualitativa das respostas revelou casos em que o modelo reproduziu regras da base pública original que haviam sido removidas das demonstrações, sugerindo forte influência da memorização. Concluímos que a hipótese de generalização irrestrita estava incorreta e que os modelos atuais operam em um regime híbrido, combinando heurísticas visuais básicas com dependência de padrões memorizados. Todos os datasets gerados, códigos e logs de execução serão disponibilizados publicamente para a comunidade.

Palavras-chave: ARC-AGI, Raciocínio Espacial, Inteligência Artificial, Memorização em LLMs, Cadeia de Pensamento, Invariância Geométrica.

1 Introdução

A busca por Inteligência Artificial Geral (AGI) requer testes que consigam diferenciar a simples memorização de dados da verdadeira capacidade de raciocínio e adaptação a problemas inéditos.

Proposto por François Chollet em 2019 [1], o benchmark ARC-AGI (*Abstraction and Reasoning Corpus*) foi concebido especificamente para esse propósito, desafiando sistemas a induzir regras lógicas a partir de poucos pares de matrizes coloridas de entrada e saída (*few-shot learning*).

Diferente de testes puramente textuais, o ARC avalia habilidades visuais e espaciais básicas, como reconhecimento de objetos, noções de simetria, conectividade e topologia. Contudo, o conjunto de treinamento com 400 tarefas é público e está indexado na internet há mais de sete anos. Como os Grandes Modelos de Linguagem (LLMs) contemporâneos são treinados sobre bases com trilhões de tokens, existe uma probabilidade real de contaminação de dados. Isso levanta a pergunta central desta pesquisa: **os modelos de linguagem acertam as tarefas do ARC porque realmente compreendem a lógica geométrica ou porque decoraram as matrizes canônicas vistas durante o pré-treinamento?**

Para responder a essa pergunta, realizamos uma avaliação comparativa entre dois modelos modernos desenvolvidos pelo Google: o **Gemma 4 (31B-IT)**, um modelo aberto de alta capacidade paramétrica com raciocínio profundo, e o **Gemini 3.5 Flash Lite**, um modelo proprietário altamente otimizado para velocidade e eficiência. Em vez de apenas medir a acurácia estática na base pública, criamos um ambiente experimental que testa a estabilidade dos modelos diante de perturbações espaciais e de cores, verificando se o raciocínio se mantém quando a aparência visual do problema é modificada.

Com o objetivo de contribuir com a pesquisa aberta e permitir a reprodutibilidade integral deste estudo, todos os códigos desenvolvidos, os novos conjuntos de dados transformados e os logs completos de pensamento dos modelos serão disponibilizados publicamente em repositório aberto.

2 Hipótese

A nossa investigação parte de uma pergunta direta sobre a capacidade dos modelos de linguagem: *eles possuem inteligência geral (AGI)?* Com base nisso, estruturamos a nossa hipótese central e o cenário alternativo correspondente:

- **Hipótese Central (Existe AGI):** Assumimos inicialmente que os modelos de linguagem possuem capacidade de raciocínio abstrato genuíno (AGI). Sob essa hipótese, o modelo compreende verdadeiramente a regra lógica que governa a transformação das matrizes. Como consequência direta, aplicar transformações espaciais simples que preservam a estrutura do problema — como rotacionar, refletir ou permutar cores — **NÃO altera** o resultado, e o modelo deve manter a mesma taxa de acerto observada nas tarefas originais.
- **Contra-Hipótese (A Hipótese Inicial está Incorreta):** Caso a nossa hipótese inicial esteja errada e os modelos não possuam AGI, o seu sucesso depende de padrões canônicos e soluções memorizadas durante o pré-treinamento na base pública. Nesse cenário, rotacionar, refletir ou permutar as cores **PODE alterar** o resultado, provocando quedas expressivas de desempenho quando as tarefas são modificadas ou combinadas em formatos inéditos.

3 Metodologia e Desenvolvimento

Para testar as hipóteses de forma rigorosa e controlada, desenvolvemos uma metodologia dividida em duas frentes principais: um pipeline de execução em duas chamadas independentes e um gerador formal de transformações matriciais.

A avaliação de LLMs em tarefas de matrizes numéricas pode sofrer com erros triviais de formatação de texto (como esquecer colchetes ou vírgulas), o que mascararia a real capacidade de raciocínio do modelo. Para isolar a resolução lógica da extração sintática, estruturamos o teste de cada tarefa em duas etapas consecutivas:

1. **Etapla de Raciocínio (*Reasoning*):** O modelo recebe o JSON com os exemplos de treino e a entrada de teste. O prompt orienta o modelo a raciocinar livremente em linguagem natural, explorando hipóteses, descrevendo os objetos e formulando a matriz prevista. Essa chamada é executada com temperatura $T = 0.6$ e modo de pensamento profundo (*High Thinking*), incentivando a busca por soluções.
2. **Etapla de Extração e Formatação (*Formatting*):** O modelo recebe a saída gerada na etapa anterior e atua de maneira determinística, com temperatura $T = 0.0$ e pensamento mínimo. Sua única função é localizar a resposta no texto e retornar estritamente a matriz numérica final, garantindo a comparação exata com o gabarito.

Essa separação também nos permitiu auditar o tempo de inferência e os tokens consumidos de maneira precisa. Como as chamadas de raciocínio profundo duram de dezenas a centenas de segundos enquanto a latência de rede típica fica abaixo de 300 milissegundos, mais de 99,9% do tempo medido reflete processamento computacional puro do modelo nas TPUs.

Para garantir que a avaliação das transformações fosse justa, não aplicamos as transformações sobre a base inteira de forma indiscriminada. Em vez disso, isolamos exclusivamente as tarefas que cada modelo havia acertado na base original de treino (304 tarefas para o Gemma e 270 para o Gemini) e geramos quatro conjuntos derivados:

- **Rotação:** Matrizes de entrada e saída rotacionadas no mesmo ângulo (90° horário, 180° ou 90° anti-horário), com correspondência exata ($Input \equiv Output$).
- **Reflexão:** Matrizes espelhadas no mesmo eixo (horizontal ou vertical), com correspondência exata ($Input \equiv Output$).
- **Coloração:** Permutação bijetiva de cores com suporte à troca da cor de fundo (cor 0), preservando a paleta na entrada e na saída ($Input \equiv Output$).
- **Merged (Composto):** Combinação de múltiplas transformações simultâneas (rotação, reflexão e troca de cores), gerando duas variações por problema original com operadores independentes na entrada e na saída.

4 Resultados Experimentais

A avaliação empírica dos modelos revelou padrões claros sobre o comportamento de cada arquitetura quando submetida a diferentes tipos de perturbação visual. O ponto de partida foi a medição da acurácia global obtida na base de treino original (400 tarefas) e a subsequente taxa de retenção nos conjuntos transformados. A Tabela 1 apresenta esses resultados de forma comparativa.

Tabela 1: Taxa de Acurácia Global e Comparativo de Desempenho.

Dataset	Gemma 4 (31B)	Gemini 3.5 Flash Lite	Diferença (Δ)
Original (Treino)	76,00% (304/400)	67,50% (270/400)	+8,50 pp
Rotated	87,17% (265/304)	85,56% (231/270)	+1,62 pp
Reflected	87,50% (266/304)	87,04% (235/270)	+0,46 pp
Coloration	89,14% (271/304)	84,44% (228/270)	+4,70 pp
Merged (Composto)	44,50% (263/591)	35,93% (194/540)	+8,57 pp

Ao analisarmos a Tabela 1, fica evidente que os modelos mantiveram alta estabilidade diante de transformações isoladas de simetria (Rotação, Reflexão e Coloração), preservando entre 84%

e 89% dos acertos em relação às tarefas que haviam dominado na base original. Em reflexão e rotação, a proximidade dos percentuais indica um empate técnico na consistência com que ambos aplicam operadores geométricos básicos. Contudo, quando múltiplas transformações foram combinadas no conjunto Merged, o rendimento sofreu uma quebra acentuada, caindo para 44,50% no Gemma e 35,93% no Gemini, o que representa quedas superiores a 40 e 50 pontos percentuais. A Figura 1 ilustra esse contraste no desempenho.




Figura 1: Comparativo de Acurácia (%) entre Gemma 4 (31B-IT) e Gemini 3.5 Flash Lite nos 5 conjuntos de tarefas avaliados.

Para entender o esforço computacional despendido pelos modelos, avaliamos o consumo de tokens de pensamento (*Thinking Tokens*) gerados durante a fase de raciocínio. A fim de estabelecer uma comparação estritamente justa e neutra, esse cálculo foi realizado considerando exclusivamente a intersecção de tarefas compartilhadas que ambos os modelos acertaram na base original (S_{shared} , $N = 252$). A Tabela 2 resume as médias e desvios padrão obtidos.

Tabela 2: Consumo Médio de Tokens de Pensamento em Tarefas Corretas na Intersecção ($N = 252$).

Dataset	Gemma 4 (Tokens)	Gemini 3.5 Flash Lite (Tokens)	Diferença (Δ Tokens)
Original	$9.856,1 \pm 3.411,4$	$9.462,6 \pm 4.906,4$	+393,4 tokens
Rotated	$9.851,3 \pm 3.921,2$	$8.944,5 \pm 4.562,3$	+906,8 tokens
Reflected	$9.732,0 \pm 3.694,2$	$8.918,5 \pm 4.411,4$	+813,5 tokens
Coloration	$9.923,4 \pm 3.393,4$	$8.991,8 \pm 4.402,8$	+931,7 tokens
Merged	$11.537,0 \pm 3.790,9$	$10.504,4 \pm 4.773,9$	+1.032,5 tokens

Conforme demonstrado na Tabela 2, o gasto médio de tokens de pensamento permaneceu bastante estável nas transformações simples de simetria (≈ 8.900 a 9.900 tokens). No entanto, diante do conjunto Merged, ambos os modelos aumentaram significativamente a quantidade de tokens gerados (superando 10.500 no Gemini e 11.500 no Gemma), o que dá indícios de uma busca exploratória mais prolongada na tentativa de reconciliar regras compostas inéditas. A Figura 2 apresenta a visualização gráfica dessa métrica.




Figura 2: Consumo Médio de Tokens de Pensamento em Tarefas Corretas sobre a Intersecção de Tarefas Compartilhadas ($N = 252$).

Por fim, analisamos o tempo puro de inferência gasto por tarefa correta, calculado sobre a mesma intersecção compartilhada ($N = 252$). A Tabela 3 sintetiza a comparação de latência entre os dois modelos.

Tabela 3: Tempo Médio de Inferência Pura (segundos) por Tarefa Correta na Intersecção ($N = 252$).

Dataset	Gemma 4 (Tempo)	Gemini 3.5 Flash Lite (Tempo)	Aceleração do Gemini
Original	208, 1s $\pm$ 73, 2s	27, 5s $\pm$ 19, 4s	7,6$\times$ mais rápido
Rotated	222, 4s $\pm$ 105, 1s	31, 3s $\pm$ 22, 3s	7,1$\times$ mais rápido
Reflected	218, 9s $\pm$ 93, 8s	28, 7s $\pm$ 25, 2s	7,6$\times$ mais rápido
Coloration	227, 9s $\pm$ 99, 3s	28, 0s $\pm$ 21, 0s	8,1$\times$ mais rápido
Merged	285, 1s $\pm$ 131, 5s	32, 5s $\pm$ 27, 9s	8,8$\times$ mais rápido

Os dados da Tabela 3 apontam para uma enorme diferença de eficiência prática: enquanto o Gemma 4 (31B) levou em média mais de 200s a 285s por tarefa correta devido ao seu tamanho e processamento denso, o Gemini 3.5 Flash Lite completou as mesmas tarefas em média entre 27s e 32s, sendo entre **7,1 e 8,8 vezes mais rápido**. A Figura 3 destaca visualmente essa diferença nos tempos de execução.




Figura 3: Tempo Médio de Inferência Pura (segundos) por Tarefa Correta sobre a Intersecção de Tarefas Compartilhadas ($N = 252$).

5 Discussão

Ao analisarmos em conjunto os resultados numéricos e o texto produzido pelos modelos durante o raciocínio, encontramos indícios importantes sobre como eles operam na prática, ajudando a entender onde eles realmente aplicam lógica visual e onde aparentam depender de respostas prontas.

Um dos indícios mais expressivos dessa dinâmica ocorreu durante a avaliação da tarefa `f1cefba8` no conjunto Merged. Na base pública original do ARC (disponível desde 2019), essa tarefa opera segundo um ciclo de cores específico ($2 \rightarrow 3 \rightarrow 8 \rightarrow 2$). Ao construirmos a versão modificada da tarefa, essa regra cíclica foi intencionalmente alterada nos exemplos de demonstração fornecidos no prompt. Contudo, ao inspecionarmos o texto de raciocínio gerado pelo Gemma 4 (31B-IT), o modelo escreveu textualmente: “...following the cycle 2 -> 3 -> 8 -> 2...”. Como essa regra havia sido removida no JSON transformado, esse comportamento sugere que o modelo possivelmente ignorou os novos exemplos presentes no contexto e provavelmente resgatou a regra que havia memorizado durante o pré-treinamento, falhando na resolução final. Esse resultado deixa a entender que parte do sucesso observado em benchmarks públicos pode ser impulsionado por dados previamente memorizados.

Por outro lado, a alta consistência mantida em transformações simples de simetria ($\approx 85\%$ a 89% de acerto em Rotação, Reflexão e Coloração) mostra que os modelos não atuam meramente como tabelas estáticas de consulta para matrizes idênticas. Eles demonstram capacidade funcional de aplicar operadores espaciais isolados sobre problemas que já sabem resolver. O ponto de ruptura evidente ocorre na composição: quando múltiplos operadores são combinados de forma inédita no conjunto Merged, os modelos perdem a âncora dos padrões canônicos memorizados e o desempenho sofre uma queda expressiva.

5.1 Comparativo de Perfil entre os Modelos

A comparação entre o Gemma 4 (31B) e o Gemini 3.5 Flash Lite revela dois perfis práticos bem delineados:

- **Gemma 4 (31B-IT):** Apresenta maior taxa de acerto absoluto (+8,50 pp na base original e +8,57 pp no Merged), sugerindo que o maior volume de parâmetros pode auxiliar na

retenção de detalhes lógicos complexos na janela de contexto, mas com o custo de um processamento significativamente mais demorado ($\approx 200s$ a $285s$ por tarefa).

- **Gemini 3.5 Flash Lite:** Apresenta consistência praticamente equivalente em simetrias isoladas (diferença de apenas 0,46 pp em reflexão), aliada a uma velocidade de inferência substancialmente superior ($\approx 27s$ a $32s$ por tarefa, sendo até $8,8\times$ mais rápido), o que o torna muito mais viável e eficiente para pipelines práticos com grande volume de dados.

6 Conclusão

Este trabalho investigou experimentalmente a capacidade de raciocínio versus memorização no benchmark ARC-AGI, avaliando o Gemma 4 (31B-IT) e o Gemini 3.5 Flash Lite sob transformações espaciais e de cores.

A nossa hipótese inicial de que os modelos possuiriam capacidade geral e irrestrita de raciocínio (AGI) estava **incorreta**. Em resumo, para ambos os modelos, enquanto a acurácia se manteve estável diante de simetrias isoladas (rotação, reflexão e troca de cores), o desempenho despencou de forma severa no conjunto Merged, refutando a tese de generalização plena. Somado a isso, o registro de casos em que o modelo recuperou regras da base pública original em matrizes modificadas deixa a entender que parte do sucesso dos modelos em benchmarks públicos decorre de dados previamente memorizados.

Os modelos de linguagem atuais operam, portanto, em um **regime híbrido**: demonstram capacidade indutiva funcional para aplicar operadores geométricos elementares, mas mostram-se frágeis diante de composições inéditas que quebram os padrões canônicos vistos no pré-treinamento.

6.1 Trabalhos Futuros e Dados Abertos

Com o objetivo de contribuir com a pesquisa e incentivar novos estudos, todos os datasets transformados gerados neste trabalho, os códigos do avaliador e os logs completos de raciocínio serão disponibilizados publicamente em repositório aberto para a comunidade acadêmica. Além disso, destacam-se três direções principais de continuidade:

1. **Análise Cruzada de Falhas:** Comparar os erros cometidos simultaneamente por Gemma e Gemini nas mesmas tarefas para verificar se os modelos convergem para a mesma lógica falha.
2. **Taxonomia de Erros:** Classificar detalhadamente os tipos de falha (erros de dimensão, ruídos, perda de cores ou alucinação de regras antigas) para encontrar padrões estruturados.
3. **Avaliação de Modelos Maiores:** Testar modelos de maior escala para verificar se a invariância composicional emerge com o aumento de capacidade.

Referências

- [1] F. Chollet, “On the Measure of Intelligence,” *arXiv preprint arXiv:1911.01547*, 2019. Disponível em: <https://arxiv.org/abs/1911.01547>
- [2] J. Wei, X. Wang, D. Schanz, S. Ho, H. S. Chowdhery, et al., “Chain-of-Thought Prompting Elicits Reasoning in Large Language Models,” *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 35, pp. 24824–24837, 2022. Disponível em: <https://arxiv.org/abs/2201.11903>

- [3] C. Snell, J. Lee, K. Xu, and A. Kumar, “Scaling LLM Test-Time Compute Optimally can be More Effective than Scaling Model Parameters,” *arXiv preprint arXiv:2408.03314*, 2024. Disponível em: <https://arxiv.org/abs/2408.03314>
- [4] T. Brown, B. Mann, N. Ryder, M. Subbiah, et al., “Language Models are Few-Shot Learners,” *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 33, pp. 1877–1901, 2020. Disponível em: <https://arxiv.org/abs/2005.14165>
- [5] E. S. Spelke and K. D. Kinzler, “Core Knowledge,” *Developmental Science*, vol. 10, no. 1, pp. 89–96, 2007. Disponível em: <https://doi.org/10.1111/j.1467-7687.2007.00569.x>